

NetzPilot — Methodik & Validierung

Stand: 2. Juni 2026. Dieses Dokument beschreibt, was NetzPilot tut, wie es geprüft wurde und — ebenso wichtig — was (noch) NICHT belegt ist. Alle Zahlen stammen aus reproduzierbaren Läufen im Repository; die Quelle ist je Abschnitt genannt. Es werden keine Werte behauptet, die nicht aus einem Artefakt nachvollziehbar sind.

1. Kurzfassung

NetzPilot ist eine Day-ahead-Prognose- und §14a-Koordinationssoftware für kleine Stadtwerke und Verteilnetzbetreiber. Sie sagt die Verteilnetz-Last bzw. Residuallast des nächsten Tages stündlich mit Unsicherheitsband (P10/P50/P90) voraus und leitet daraus zwei operative Funktionen ab: eine faire, minimale §14a-Steuerung steuerbarer Verbrauchseinrichtungen bei Netzengpässen und eine realistische Abschätzung der Bilanzkreis-/Ausgleichsenergie-Exposure.

Belegt ist heute: Die Prognose schlägt auf **46 echten, öffentlichen Netz-/Regionallastgängen** auf dem statistisch sauberen 84-Tage-Fenster in **44 von 46 Reihen signifikant** die naive Branchenpraxis (Saisonal-Naiv; mittlerer Skill +23,7 %; die zwei Ausnahmen sind Quasi-Duplikate der Herne-Niederspannung mit +3,1 % bei P(Model besser)=92 % — ehrliche Grenzfälle, kein Gegenbeweis; gegen Persistenz gewinnt die große Mehrzahl). Die §14a-Optimierung reduziert die Abregelung gegenüber pauschalem Dimmen erheblich und hält dabei nachweislich Netzgrenze und gesetzliche Mindestleistung ein. Der €-Nutzen aus vermiedener Ausgleichsenergie ist **reihen- und regimeabhängig** — bei manchen Netzen robust positiv, bei anderen nahe null — und wird ehrlich mit Unsicherheitsband statt als feste Zahl ausgewiesen. Der theoriegestützte, robuste Hebel ist die **News vendor-Logik** (§9): bei asymmetrischer Ausgleichsenergie-Bepreisung senkt die Nominierung des kostenoptimalen τ -Quantils statt des Medians die Kosten nachweisbar, wachsend mit der Asymmetrie (leakage-sicher belegt; prozentual übertragbar, absolute € nur illustrativ).

Nicht belegt ist: ein Live-Pilot mit der echten, kundeneigenen RLM-Gesamtlast und echter reBAP-/Bilanzkreis-Abrechnung. Bis dahin sind alle Lastgänge öffentliche DSO-Reihen, die als Proxy für die Bilanzkreis-Entnahme dienen. Das ist die einzige echte Validierungslücke — und sie ist bewusst so benannt. Das Instrument, sie zu schließen, läuft bereits: jede ausgegebene Prognose wird hash-verkettet **zum Ausgabezeitpunkt** gespeichert und gegen eintreffende Ist-Werte abgerechnet (Live-Track-Record, §12).

2. Problemstellung & Geltungsbereich

Kleine Stadtwerke stehen unter wachsendem Druck: §14a EnWG verpflichtet Netzbetreiber, steuerbare Verbrauchseinrichtungen (Wärmepumpen, Wallboxen, Speicher) netzdienlich zu steuern, ohne sie unzulässig zu benachteiligen; gleichzeitig verursachen Prognosefehler im Bilanzkreis Ausgleichsenergiekosten. Große Tools (KISTERS, Seven2one) adressieren das, sind für kleine EVU aber teuer und schwer.

NetzPilot zielt auf die day-ahead-Ebene: 24×1 h Prognose der Last/Residuallast mit P10/P50/P90, daraus ein §14a-Fahrplan und eine €-Einordnung. Der Geltungsbereich ist bewusst eng gehalten — keine Intraday-Handelsoptimierung, keine Behauptung, „genauer als kommerzielle Profitools“ zu sein (ein solcher Direktvergleich wurde nicht gefahren).

3. Datengrundlage & Provenienz

Eine zentrale Disziplin des Projekts ist die strikte Trennung **echter** von **modellierter** Datenbasis. Es wird nie über NaN gemittelt; Reihen mit identischem Werte-Hash werden vor jeder Zählung dedupliziert.

Validierungskorpus (echt): 51 eingelesene Einträge → nach Inhalts-Deduplikation **46 eindeutige Reihen**, nach Korrelations-Deduplikation (Pearson $r \geq 0,98$, transitive Cluster) **38 unabhängige Netz-/Regionalcluster**. Aufteilung: 43 deutsche, 3 französische Reihen (Quelle: data_cache/real/corpus_index.json, network_independence.md). Es handelt sich um nach §12/§23c bzw. national veröffentlichte Lastgänge realer Netzbetreiber (u. a. Hilden, Herne, EVDB, Neuruppin, Bitterfeld-Wolfen, Waren, TEN Thüringer Energienetze, neu.sw Neubrandenburg, Passau; Enedis FR, RTE FR).

Bewusst gesondert behandelt: - **SLP-Summenlast** (1 Reihe): ein veröffentlichter Standardlastprofil-Summengang ist nahezu deterministisch; die niedrige MAPE dort (Hilden 1,8 %, Skill +34 %) ist „zu einfach“ und wird NICHT als Realnachweis geführt. Das ehrliche Headline ist der Netzsatz, nicht die SLP-Summe. - **Signierte Differenzbilanz-Reihen** (7 Reihen): Mittelwert ≈ 0 → MAPE bedeutungslos; dort führt der Skill/MAE, nicht die Prozentzahl. - **Modellierte „City“-Profile**: synthetische Profile (Cross-City $r \approx 0,89-0,98$) dienen nur der Entwicklung, nicht als Beweis. Sie sind nicht Teil des Validierungskorpus. - **Nationale Last (ENTSO-E)**: getrennt gehalten (data_cache/intl/) und nie als Verteilnetz gezählt.

Preisdaten (echt): reBAP 2024 (regelzonenübergreifend, netztransparenz.de, Viertelstunden) und Day-ahead-Spot 2024 (data_cache/real/).

4. Prognosemethode

Das Modell ist bewusst einfach und robust statt komplex:

Basis — Saisonal-Naiv: die Last der Vorwoche zum gleichen Wochentag und zur gleichen Stunde. Eine starke, transparente Baseline.

Korrektur — ShrinkCorrector: eine Ridge-Regression auf leakage-sichere Kalender- und Lag-Features, mit **Shrinkage Richtung Baseline**. Pro Fit wird auf einem Out-of-sample-Tail ein Faktor $s \in [0,1]$ gewählt, der den MAE minimiert. Hilft die Korrektur nicht, geht $s \rightarrow 0$ und das Modell fällt auf die Baseline zurück. Das ist die zentrale Vertrauenseigenschaft: **NetzPilot wird nie deutlich schlechter als die triviale Baseline** — entscheidend für ein Werkzeug, das im Betrieb unbeaufsichtigt läuft.

Unsicherheit — Conformalized Quantile Regression (CQR): liefert P10/P50/P90 mit verteilungsfreier marginaler Coverage-Garantie. (Quelle: MODEL_CARD.md.)

Feiertagsbewusste Basis (2026-06): war der Vorwochen-Referenztag ein Feiertag, ist die Saisonal-Naiv- Basis systematisch verzerrt ($\sim 17-20$ % zu niedrig auf Aggregat-Last). Statt eines gefitteten Flags (das auf Industrie-Reihen katastrophal überfittete und verworfen wurde) weicht NetzPilot **deterministisch** auf die nächste Nicht-Feiertags-Referenz gleichen Wochentags aus ($d-14$, $d-21$, ...). Parameterfrei, leakage-sicher, bit-identisch an allen anderen Tagen. Gemessen: +2,7...3,2 % MAE auf Aggregat-Reihen, $\approx$ neutral auf Industrie. (scripts/verify_holiday_base.py, Demo holiday_base_demo.md.)

Online-Residuen-Feedback (2026-06): die Modell-Residuen sind über alle echten Reihen signifikant lag-1-autokorreliert ($+0,18...+0,44$) — persistente Regime-Fehler, die die Features nicht voll abbilden. Ein Anteil p des zuletzt **beobachteten** Residuums wird auf die nächste Prognose addiert (Level-Shift auf P10/P50/P90 gemeinsam); p wird online auf einem nachlaufenden Fenster getunt und zur 0 geschrumpft — adaptiv: starke Autokorrelation → Gewinn, schwache → No-Op. Gemessen: 5/5 echte Reihen besser, mean +1,6 % MAE, Pinball nie schlechter. (scripts/verify_residual_feedback.py, Demo residual_feedback_demo.md.)

Coverage-Kalibrierung, online-rollend und asymmetrisch (2026-06): die rohen P10/P90 sind je Reihe unterschiedlich und zweiseitig fehlkalibriert; zusätzlich sind die Fehler rechtsschief (Lastspitzen drücken über P90). NetzPilot skaliert daher die untere und obere Bandhälfte **getrennt**, mit je Tag aus dem nachlaufenden 28-Tage-Fenster getunten, geschrumpften Faktoren (leakage-sicher: nie der Zieltag). Gemessen @84 Testtagen: mittlerer Coverage-Fehler ~halbiert (4,73→2,66 Punkte), beide Tails ≈10 % (Soll), Pinball in keinem Fall schlechter. Naive und kalibrierte Coverage werden immer nebeneinander berichtet. (scripts/verify_rolling_calibration.py, verify_asymmetric_calibration.py.)

Kumulativ: die P50-Mechanismen komponieren additiv (4-Arm-Messung, gleiche Eval-Tage): Aggregat-Reihen **+3,1...3,2 % MAE gesamt** (Hilden +3,17 %, Herne +3,12 %), Industrie ≈neutral — keine negative Interaktion. (STAND_PROGNOSEKERN_2026-06-03.md.)

4a. Temporale Reconciliation statt Spannungsebenen-Zwang

MinT-Reconciliation wird in NetzPilot nur auf Hierarchien angewandt, deren Summenidentität an den Rohdaten gilt. Die naheliegende Idee, veröffentlichte Netzlastreihen verschiedener Spannungsebenen als Parent = Sum(Children) zu reconcilieren, wurde an echten Daten getestet und verworfen: diese Reihen sind eine vertikale Kaskade mit Entnahme je Ebene, keine additive Hierarchie.

geprüfte Identität (TEN 2025, 35.040 Viertelstunden)		
	Ergebnis	mittlere rel. Abweichung
HS = HSU + MS	nein	38,8 %
HS = HSU + MSU + NS	nein	70,6 %
MS = MSU + NS	nein	108,3 %
MSU = NS	Quasi-Duplikat, kein Mehrwert	2,2 %

Konsequenz: Eine cross-sektionale Spannungsebenen-Reconciliation würde reale Daten auf eine falsche physikalische Constraint biegen. NetzPilot nutzt MinT stattdessen auf der temporal exakten Achse einer einzigen 15-min-Reihe: Tagesenergie = Summe der 24 Stunden = Summe der 96 Viertelstunden. Auf Hilden Netzumsatz 2025 (data_cache/benchmark/reconcile_temporal_demo.md) sinkt der maximale Kohärenzfehler im 14-Tage-Holdout von 44,369193 MWh auf 0,000000 MWh; MAE wird je Ebene ehrlich ausgewiesen.

5. Evaluationsprotokoll

Vier Regeln, die jeden Validierungslauf binden (Quelle: MODEL_CARD.md, benchmark_suite.py):

1. **Leakage-sicher:** rolling-origin (expanding window) — das Modell sieht beim Vorhersagen nie den Zieltag. Sämtliche berichteten Zahlen sind Out-of-sample.
2. **Baselines verpflichtend:** Persistenz UND Saisonal-Naiv in jedem Lauf. Skill wird immer relativ zu beiden ausgewiesen.
3. **Signifikanz:** paired Block-Bootstrap mit Block = ganzer Tag (respektiert die Intraday-Korrelation), 95 %-Konfidenzintervall des Skill + Wahrscheinlichkeit „Modell besser“.
4. **NaN/Inf-sicher:** nicht-finite Werte werden vor jeder Mittelung verworfen.

5. **Ausreichende Test-Power (Audit 2026-06-03):** das frühere Default-Fenster von 28 Testtagen war statistisch unterpowert — 11 echte Reihen galten fälschlich als „nicht signifikant“ (Punktschätzung stabil, CI nur zu breit). Bei **84 Testtagen (12 Wochen)** wurden im finalen Voll-Board (2026-06-04) **44 von 46 Reihen signifikant**; zwei Herne-NS-Quasi-Duplikate (+3,1 %, P(besser)=92 %) bleiben ehrlich n.s. Headline-Fenster ist seither 84 Tage.

Reproduktion: `python scripts/benchmark_suite.py → benchmark_table.md + benchmark_results.json` (Seed 20260601, **84 Testtage** rollierend, 10 000 Bootstrap-Resamples). Voll-Stack-Variante mit Residuen-Feedback + Online-Kalibrierung: `--residual-feedback --calibrate` → separat benannte Dateien (`..._rf_cal.json/.md`); Fortschritts-Dateien sind je Flag-Kombination getrennt, ein Resume kann Mechanismen nie mischen.

6. Validierungsergebnisse (Prognose)

Auf dem statistisch sauberen **84-Tage-Fenster** (siehe §5, Regel 5) schlägt NetzPilot Saisonal-Naiv in **44 von 46 Reihen signifikant** (mittlerer Skill **+23,7 %**, Median +21,4 %; Ausnahmen: zwei Herne-NS-Quasi-Duplikate, +3,1 % bei P(besser)=92 % — ehrliche Grenzfälle). Voll-Board final gerechnet am 2026-06-04 (venv, Seed 20260601, 10 000 Bootstrap-Resamples). Die verteidigten Echtdaten-Headlines (echter Netzbezug, kein SLP-Summengang; 84 Testtage):

Reihe	Mittl. Last	MAPE	Skill vs S-Naiv (CI95)	Cov P10–P90 (Board)
Hilden — Netzsatz 2025	29,2 MW	3,5 %	+18,9 % [+10,5, +26,7] *	84,3 %
Herne — Bezug 110/10 kV 2024	49,3 MW	3,9 %	+27,5 % [+17,6, +36,7] *	81,8 %
EVDB — Lastgang NS 2024	6,0 MW	4,8 %	+37,9 % [+30,5, +44,5] *	85,5 %

Lesart: „Skill“ = Fehlerreduktion gegenüber der Baseline. * = signifikant (CI95-Untergrenze > 0). Die frühere Aussage „Hilden n.s.“ war ein **Power-Artefakt des 28-Tage-Fensters** — bei 84 Tagen ist der Vorsprung klar signifikant. Das Board enthält die **feiertagsbewusste Basis** (§4) — sichtbar z. B. an Hilden +16,4 → +18,9 % gegenüber dem Vor-T48-Stand — aber bewusst **ohne** Online-Residuen-Feedback und ohne Online-Kalibrierung: deren Zusatzgewinne (+1,6 % bzw. Coverage-Fehler halbiert, §4) sind separat leakage-sicher belegt und kommen additiv obendrauf. Die Board-Coverage ist daher die **unkalibrierte** Band-Coverage (Korpus-Mittel 78,9 % bei Soll 80 %).

Französische Aggregate (Enedis, RTE): hohe Skills gegen Saisonal-Naiv (+45,2 % / +51,3 % / +37,0 %), aber gegen **Persistenz** bleiben zwei der drei Reihen nicht signifikant (−5,5 % / +0,4 %; nur eco2mix +11,5 % sig) und die Band-Coverage ist schwach (57–62 %). Grund: die Regional-Aggregate sind so glatt, dass Persistenz schwer zu schlagen ist. Das wird offen benannt — es ist kein Verteilnetz-Nachweis, sondern zeigt die Grenze der Methode bei sehr glatten Reihen. (Quelle: `benchmark_table.md`.)

Wetter: Eine leakage-sichere Wetter-Integration brachte **keinen** signifikanten Genauigkeitsgewinn. Es gibt kein „Wetter-Wunder“; diese Sackgasse ist dokumentiert statt verschwiegen.

7. §14a-Koordination

Bei einem prognostizierten Netzengpass dimmt die Branchenpraxis alle steuerbaren Einrichtungen pauschal auf die garantierte Mindestleistung (4,2 kW). NetzPilot rechnet stattdessen die **minimale, faire** Abregelung:

Wasserfüll-Optimierung (`control/optimize.py`): verteilt die nötige Leistungsreduktion so, dass die Netzgrenze exakt gehalten wird, jede Einrichtung ihre §14a-Mindestleistung behält und

die Gesamt- abregelung **beweisbar minimal** ist (analytisch exakt per Wasserfüllung, kein Solver; verifiziert in `verify_optimize_heterogen.py`). Wie viel das gegenüber pauschalem Dimmen konkret spart, hängt vom Engpass ab — die end-to-end gemessene Größenordnung liefert der rollierende Re-Dispatch (nächster Absatz).

Rollierender Re-Dispatch (`control/redispatch.py`): statt eines starren Vortagsplans wird der Eingriff stündlich mit der jeweils aktuellen Prognose nachgeführt — kein unnötiges Dimmen in Stunden, die sich kurzfristig als unkritisch erweisen. Auf 3 echten Reihen im Mittel **74,3 % weniger Abregelenergie** als pauschale Dauerdimmung, Netzgrenze und 4,2-kW-Floor in 3/3 Fällen gehalten. **Ehrliche Einschränkung:** die Engpassschwelle ist hier synthetisch (knapp unter die Tagesspitze gesetzt; echte Schwelle = reale Netzkapazität im Pilot), und die Prognosebasis ist als statische Day-ahead-P50 gekennzeichnet — der größere Intraday-Vorteil ist damit noch nicht bewiesen. (Quelle: `redispatch_demo.md`.)

Heterogene Flotte (`optimize_setpoints_heterogen`): generalisiert die Optimierung auf einen Mix aus Wärmepumpe/Wallbox/Speicher mit je eigener Mindestleistung und Gewichtung — minimal, fair und §14a-sicher, ohne das verifizierte homogene Verhalten zu ändern.

Audit-Trail: `service/audit_ledger.py` dokumentiert Redispatch-, Dispatch- und Tarif-Eingriffe als append-only JSONL-Hash-Kette. Jeder Eintrag enthaelt Grund, Dauer, `magnitude_kw`, betroffene Limits und Regelversion; `verify_chain` erkennt nachtraegliche Aenderungen mit Bruchindex. Der druckbare Nachweis enthaelt den Ketten-Kopf-Hash und optional eine HMAC-SHA256-Signatur. Ehrliche Grenze: Das ist ein **manipulationssicherer Audit-Trail (Hash-Kette)**, nicht BNetzA-zertifiziert und keine Behauptung juristischer Rechtssicherheit. Die Diskriminierungsfreiheit entsteht aus der Wasserfuellung; das Ledger dokumentiert sie nachpruefbar.

NetzPilot berührt dabei nie selbst das Smart-Meter-Gateway: es erzeugt White-Label-Fahrpläne für den aEMT.

8. Ökonomie: Bilanzkreis-/Ausgleichsenergie

Die naheliegende €-Erzählung wäre „spart X €/Jahr“. Eine ehrliche Analyse zeigt: **so einfach ist es nicht**. Bessere Prognosen senken nur dann Ausgleichsenergiekosten, wenn die vermiedenen Abweichungen mit teuren Preisstunden zusammenfallen — eine Korrelation, die pro Netz und Preisjahr verschieden ist.

NetzPilot rechnet die **echte Viertelstunden-Abrechnung**: pro Periode der signierte Prognosefehler mal dem reBAP-minus-Spot-Aufschlag (`eval/bilanzkreis.py`), zerlegt in einen Bias- und einen Korrelationsterm. Auf langen 2024-Fenstern (≈ 300 gemessene Tage, leakage-sicher rolling-origin):

Reihe	realisiert €/Jahr	lineare Näherung €/Jahr	MC-Band P5/P50/P95	P(spart)
Herne 110/10 kV	1 566	29 784	[−136 724, 1 635, 133 913]	50,8 %
EVDB NS	43 732	16 787	[15 462, 42 471, 77 632]	99,9 %

Bei EVDB ist der Nutzen robust positiv; bei Herne praktisch ein Münzwurf mit großer Varianz. 30-Tage- Blöcke schwanken bei Herne zwischen −607 000 und +719 000 €/Jahr — d. h. eine kurze Messung kann jede Zahl liefern. Das **Monte-Carlo-Band** (Tages-Block-Bootstrap, `eval/mc_savings.py`) macht diese Unsicherheit explizit. (Quelle: `bilanzkreis_demo.md`.)

Produktkonsequenz: Der €-Nutzen ist keine feste Versprechung, sondern wird **pro Stadtwerk auf dessen echten Daten** gerechnet und mit Unsicherheitsband ausgewiesen. Genau diese ehrliche, mandantenspezifische Rechnung ist der Mehrwert — nicht eine plakative Sparszahl. Weitere Vorbehalte: kein Intraday-Handel modelliert (die Zahl ist eine obere Schranke der Exposure), und das reBAP-Vorzeichen ist nicht steuerbar (der Erwartungswert ist bei unverzerrtem, unkorreliertem Fehler $\sim 0 \rightarrow$ Nutzen = Downside-Schutz).

9. Entscheidungswert der Prognose-Unsicherheit (Newsvendor-Prinzip)

Der eigentliche Hebel von NetzPilot ist nicht die Prognosegenauigkeit an sich, sondern die *Nutzung der Unsicherheitsverteilung für eine günstigere Entscheidung*. Am klarsten zeigt sich das an der Bilanzkreis-Nominierung: sind Unter- und Überspeisung **asymmetrisch** bepreist ($c_{\text{short}} \neq c_{\text{long}}$), ist die kostenoptimale Day-ahead-Nominierung nicht der Median (P50), sondern das **τ -Quantil** der Prognoseverteilung mit $\tau = c_{\text{short}} / (c_{\text{short}} + c_{\text{long}})$. Das ist die Minimalstelle des Pinball-Loss (Newsvendor-Lehrsatz). Ein rein punktprognose-getriebener Dispatch nominert P50 und lässt bei Kostenasymmetrie systematisch Geld liegen.

Belegt auf echter SMARD-Netzlast, leakage-sicher (die Residuen-Quantile jedes Testtags nutzen nur frühere Tage — dieselbe rolling-origin-Regel wie der Benchmark). Realisierte Kostenreduktion der τ -Quantil- gegenüber der P50-Nominierung über mehrere Asymmetrie-Verhältnisse:

$c_{\text{short}} / c_{\text{long}}$	1,0	1,5	2,0	3,0	5,0
τ	0,50	0,60	0,67	0,75	0,83
Einsparung vs. P50	0,0 %	2,86 %	8,14 %	19,82 %	37,88 %

Bei symmetrischer Bepreisung (Verhältnis 1) ist die Einsparung exakt 0 % (Sanity-Check, per Konstruktion identisch zu P50); mit wachsender Asymmetrie steigt sie monoton. Ein wichtiger, kontraintuitiver Befund: die prozentuale Einsparung ist **invariant gegen die Fehlergröße** (doppelte Streuung → identische %) und wird allein von der **Form der Fehlerverteilung** (Schiefe/Tails) **× der Kostenasymmetrie** bestimmt — „ein verrauschteres Portfolio spart mehr“ ist also falsch.

Das ist der theoriegestützte, robuste Teil der €-Geschichte — anders als der korrelationsabhängige, reihenspezifische Effekt aus §8. **Ehrliche Grenzen:** die absoluten Eurobeträge des Experiments beziehen sich auf das bundesweite Bilanzvolumen und sind rein illustrativ — **keine NetzPilot-Umsatzzahl**; übertragbar ist allein die *prozentuale* Aussage. Eine Monetarisierung setzt voraus, dass (a) die Prognose-Quantile kalibriert sind (bei uns gut auf deutschen DSO-Reihen, schwach auf sehr glatten Aggregaten) und (b) die reale reBAP-Asymmetrie sowie die Fehler-Form des konkreten Kunden aus einem Piloten vorliegen. (Quelle: `dispatch_experiment/`, in der Sandbox reproduziert.)

10. Betrieb: Drift-Erkennung

Damit eine im Backtest kalibrierte Prognose im Dauerbetrieb nicht unbemerkt degradiert (neue Anlagen, Verhaltens- oder Sensoränderungen), vergleicht NetzPilot die jüngsten Live-Fehler gegen die Referenzverteilung (`eval/drift.py`): PSI (Industriestandard), KS (verteilungsfrei), Bias- und MAE-Verhältnis sowie die Coverage der P10/P90-Intervalle. Bei Überschreiten dokumentierter Schwellen wird „beobachten“ bzw. „Drift — neu kalibrieren“ gemeldet. Bewusst wird nur **gewarnt, nicht automatisch neu trainiert** — Drift ist ein Hinweis, kein Beweis; die Entscheidung bleibt beim Betreiber.

11. Limitationen & Ehrlichkeits-Register

In einem Dokument konsolidiert, weil Glaubwürdigkeit vom offenen Umgang mit Grenzen abhängt:

1. **Kein Live-Pilot.** Alle Lastgänge sind öffentliche DSO-Reihen als Proxy für die Bilanzkreis-Entnahme. Die kundeneigene RLM-Gesamtlast kann abweichen. Das ist die zentrale offene Validierung.

2. **Kein Vergleich gegen kommerzielle Profitools.** Keine Behauptung „genauer als KISTERS/SevenZone“.
3. **€-Zahlen aus einem Preisjahr (2024)** und mit milder Annualisierung (scale $\approx 1,2$). Ein anderes Preisregime (z. B. die Volatilität 2022) ist darin nicht enthalten.
4. **§14a-Engpassschwellen sind in den Demos synthetisch.** Die echte Schwelle = reale Netzkapazität im Pilot.
5. **Sehr glatte Aggregate** (FR-Regionen) schlägt die Methode nicht gegen Persistenz; die CQR-Coverage ist dort schwach.
6. **Wetter** brachte leakage-sicher keinen signifikanten Gewinn.
7. **SLP-Summenlast und signierte Differenzbilanzen** werden nicht als MAPE-Headlines geführt.
8. **Newsvendor-/ τ -Quantil-Einsparung (§9)** ist prozentual und theoriegestützt belegt, aber die absoluten Eurobeträge sind illustrativ (bundesweites Volumen, kein Umsatz); die Monetarisierung hängt an kalibrierten Quantilen plus realer reBAP-Asymmetrie und Fehler-Form aus einem Piloten.
9. **Gefittete Feiertags-Zusatz-Flags (Brückentag, „Vorwoche-war-Feiertag“)** wurden **geprüft und verworfen:** wirkungslos bzw. auf Industrie-Last katastrophal überfittet (1–4 Events/Jahr sind nicht robust fitbar). Verschifft wurde nur die deterministische, parameterfreie Basis-Reparatur (§4).
10. **lag-7-Residuen-Feedback** (wöchentliche Mean-Reversion, real und signifikant) wurde gemessen, aber als marginal/fragil **zurückgestellt** ($\sim +0,7$ % Mittel, eine Reihe leicht negativ) — Revisit mit Mehrjahresdaten. Feiertags-/Persistenz-Mechanismen helfen Industrie-Reihen generell nicht ($\approx$ neutral).

12. Was ein Pilot beweisen würde

Ein einziges Stadtwerk mit (a) echter RLM-Gesamtlast des Bilanzkreises, (b) echter reBAP-/Bilanzkreis-Abrechnung und (c) realer Netzkapazität als §14a-Schwelle würde drei Dinge schließen, die heute offen sind: die Übertragbarkeit der Prognosegüte von öffentlichen DSO-Reihen auf die kundeneigene Last, den realisierten €-Nutzen aus echter Ausgleichsenergie statt aus einem Proxy, und den Intraday-Vorteil des rollierenden §14a-Re-Dispatch mit echten, stündlich aktualisierten Prognosebahnen. Bis dahin gilt die hier dokumentierte, bewusst konservative Lesart.

Live-Track-Record (seit 2026-06): Die Infrastruktur für diesen Beweis läuft bereits. Jede ausgegebene Prognose wird ZUM AUSGABEZEITPUNKT in eine manipulationssichere Hash-Kette geschrieben (gleiche Mechanik wie der §14a-Audit-Trail) — damit ist **prüfbar, dass jede Prognose vor ihrem Zieltag existierte** (kein Hindsight, kein Backfill). Eintreffende Ist-Werte werden automatisch abgerechnet (MAE/Bias/Coverage je Tag, Aggregat, im Cockpit als „Live-Track-Record“ mit Ketten-Status). Das ersetzt im Laufenden den Backtest durch gelebte Prognosen gegen gelebte Realität — immer mit n Tagen + Pending ausgewiesen, ohne Zeitraum-Cherry-Picking. Ehrliche Grenze: Hash-Kette belegt Unverändertheit seit Aufzeichnung, keine juristische Zertifizierung. (netzpilot/service/forecast_store.py, scripts/verify_forecast_store.py.)

*Reproduzierbarkeit: Alle genannten Zahlen entstammen scripts/benchmark_suite.py, 'scripts/build_