

NetzPilot — Ergebnisbericht (Stand 2026-05-30)

Prognose- und §14a-Koordinationssoftware für kleine Stadtwerke. Dieser Bericht ist bewusst ehrlich gehalten: jede Zahl ist mit ihrem Verifikationsstatus versehen, und die Grenzen sind genauso prominent wie die Erfolge. Geschrieben für eine Zweitprüfung / einen kritischen Reviewer.

Verifikationskonvention

Jede Zahl ist eine von zwei Klassen:

- **[S] in der Sandbox von Claude selbst nachgerechnet** (numpy/pandas/stdlib, auf den echten Dateien) — voll reproduziert.
- **[H] Host-Lauf (Codex)**, von Claude aus den Ergebnis-/Cache-Dateien gelesen und auf Plausibilität, Leakage-Sicherheit und Provenienz geprüft — aber nicht selbst neu trainiert (Sandbox hat kein lightgbm/pvlib/Internet).

Nichts in diesem Bericht ist „geschätzt“ oder geschönt. Wo ein Ergebnis schwach oder nur ein oberer Rand ist, steht das so da.

1. Zusammenfassung (TL;DR)

NetzPilot besteht aus einer **leakage-sicheren Day-ahead-Prognose** (Last, Residuallast, Erzeugung) mit **kalibrierten Unsicherheitsbändern** und einem **§14a-Steuerkreis-Prototyp**.

Belastbar: - Nationale Last (SMARD, 2 Jahre): MAPE **3,36 %**, Skill **+55,8 %** vs. saisonal-naiv. **[H]** - 50 Stadt-Profil: MAPE **~6,7 %**, Skill **+3,9 %** vs. saisonal-naiv (positiv in **50/50**). **[S]** - Unsicherheitsbänder (CQR) sind **stadtweit kalibriert**: 80-/90-%-Coverage im Mittel 80,1 / 90,2 %, jede der 50 Städte innerhalb ± 5 pp. **[S]** - §14a-Steuerkreis end-to-end demonstriert (illegale Fahrpläne werden abgelehnt). **[S]**

Ehrlich begrenzt: - Die 50 Stadt-CSVs sind **modellerte/synthetische Profile, keine gemessenen Stadtwerke-Daten** (drei unabhängige Belege, s. §3). - Der Vorsprung gegen saisonal-naiv ist auf Stadt-/Kleinlast **dünn ($\sim +4$ %)** — die ehrliche Realität kleiner Lasten. - Der früher berichtete „**+17,9 % durch Wetter**“ (**T10**) **war Leakage** (bewiesen, s. §6). Leakage-sicher ist der Wetter-Lift ≈ 0 und nur auf wärmepumpen-/temperaturgekoppelter Last leicht positiv. - Keine echten Pilotdaten, keine realen reBAP-Kosten, kein echtes SMGW.

Kernaussage: Der belastbare Wert ist die **Prognose-Wedge + kalibrierte Bänder + §14a-Koordination**, nicht ein wetterbasierter Genauigkeits-Moat. Der nächste echte Schritt sind **reale Pilotdaten**.

2. Was NetzPilot ist

Eine schlanke Prognose-/Berechnungs-Engine: NetzPilot rechnet Day-ahead-Prognosen + Fahrpläne und gibt diese per REST/JSON an einen **zertifizierten White-Label-aEMT** (z. B. GWAdriga/GreenPocket/PPC) weiter, der die Steuerung über CLS/SMGW/HEMS ausführt. NetzPilot selbst fasst **kein** SMGW an — das ist regulatorisch und sicherheitstechnisch die richtige Trennung.

Strategie: „**Land mit der Prognose-Wedge, expandiere in §14a-/DER-Koordination.**“

3. Datenbasis & Provenienz (ehrlich)

Datensatz	Art	Verwendung	Provenienz
SMARD Netzlast + PV/Wind, 2 J	echt (ÜNB)	ationale Last/Residuallast/Erzeugung	öffentlich, real
training_cities/ (50 CSV)	modelliert/synthetisch	Stadt-Skalierung der Pipeline	s. u. — KEINE Messdaten
OPSD/CoSSMic Konstanz	echt (11 Haushalte)	Kleinlast-Proxy (T9/T10)	real, aber 2013–2017
HEAPO (Kanton Zürich)	echt (1.408 WP-Haushalte)	leakage-sicherer Wettertest (T12)	real, 2018–2024

Warum die 50 Stadt-CSVs modelliert sind — drei unabhängige Belege [S]: 1.

Identische Mittelwerte: 12 von 50 Städten teilen einen Ø-Lastwert exakt auf 0,1 MW — fünf Städte liegen alle bei **genau 69,6 MW** (Leverkusen, Ludwigshafen, Oldenburg, Osnabrück, Solingen). Reale Messlast kann nicht so zusammenfallen. 2. **Cross-City-Korrelation** der normierten Tagesform $r \approx 0,89$ – $0,98$ (Münster–Berlin 0,98). 3.

Dateinamen mehrerer Geschwisterdateien tragen „_mock“; zusätzlich zeigt T11 (§6), dass echtes lokales Wetter diese Last nicht vorhersagt → **keine echte Wetter-Kopplung** = Template-Charakter.

→ Sehr nützlich zum Entwickeln/Kalibrieren der Pipeline, **aber kein Beleg für Kunde/Gutachter.**

4. Prognose-Ergebnisse

4.1 Nationale Last & Residuallast (SMARD, 2-Jahres-Backtest) [H]

Ziel	MAE	MAPE	Skill vs. saisonal-naiv
Last	1758,8 MW	3,36 %	+55,8 %
Residuallast (direkt)	2707,1 MW	—	+52,1 %
Residuallast	2796,4 MW	—	+50,5 %

(physik. PV/Wind-
Pfad,
pvlib/windpowerlib
+ Bias)

Reproduktion v1 (12-Wochen, ridge-korrigiert) [S]: MAE 1411,4 MW (saisonal-naiv 1472,4; Persistenz 3816,2), Coverage 81,5 %.

4.2 50 Stadt-Profile (rolling-origin, 14 Testtage je Stadt) [S]

Metrik

MAPE (Last)

Skill vs. saisonal-naiv (Last)

Skill vs. saisonal-naiv (Residuallast)

Skill vs. Persistenz

MAPE liegt erwartungsgemäß zwischen national (3,4 %) und einem groben Kleinlast-Proxy (~15 %). Der Vorsprung gegen saisonal-naiv ist **dünn, aber konsistent** (jede der 50 Städte schlägt beide Baselines).

4.3 Statistische Signifikanz (paired Block-Bootstrap, Block = Tag) [S]

- **National v1** (12 Wochen): vs. saisonal-naiv +4,1 % **nicht signifikant** (CI95 [-13,1; +17,5]); vs. Persistenz +63,0 % signifikant. Erst T3 (2 J + Wetter, +55,8 %) ist statistisch belastbar.
- **Pro Stadt** (n = 14 Testtage, 10/50 gerechnet): vs. Persistenz **10/10 signifikant**; vs. saisonal-naiv **4/10** — genau die Städte mit Skill ≥ 5 %. Auf 14 Tagen ist ein Einzel-Vorsprung von $\sim +2-4$ % nicht von 0 unterscheidbar (CI-Halbweite $\sim \pm 5$ pp).
- **Aggregat**: 50/50 Städte positiv $\rightarrow$ Vorzeichentest $p \approx 10^{-15}$ (Caveat: Städte korreliert, effektives $N < 50$). **Die belastbare Aussage ist das Aggregat, nicht die Einzelstadt.**

4.4 Kalibrierung (CQR) [S national: H]

- National [H]: Last 81,2 / 87,6 %, Residuallast 82,6 / 90,9 % (Soll 80/90 %).
 - 50 Städte [S]: 80-%-Coverage Median 79,8 % (Mittel 80,1 %), 90-%-Coverage Median 90,2 %; **jede der 50 Städte innerhalb ± 5 pp** des Sollwerts. Die Bänder sind stadtweit belastbar, nicht nur national. (MAPIE/EnbPI wurde getestet, blieb unterkalibriert $\rightarrow$ belastbar ist rolling CQR.)
-

5. §14a-Steuerkreis (Prototyp) [S]

End-to-end in der Sandbox demonstriert: NetzPilot $\rightarrow$ Mock-aEMT (stdlib http.server) $\rightarrow$ simuliertes HEMS $\rightarrow$ Wallbox. Im Engpassfenster wird die Wallbox 11 $\rightarrow$ **4,2 kW** gedrosselt; **illegale Fahrpläne ($< 4,2$ kW §14a-Mindestleistung) werden vom aEMT mit HTTP 422 abgelehnt**. Das ist ein greifbarer Moat-Baustein — ohne echtes SMGW/Zertifizierung, klar als Simulation gekennzeichnet.

6. Der Wetter-Lift — die ehrliche Geschichte (T10 → T11 → T12)

Dieser Abschnitt ist das wichtigste Ehrlichkeits-Kapitel des Projekts.

1. **T10 (alt): „+17,9 % durch lokales Wetter“** auf dem Konstanz-Kleinlastproxy — sah nach dem großen Hebel aus. [H]
2. **Leakage-Beweis [S/H]:** Der T10-Lauf nutzte **2017er** Konstanz-Wetter über den „Historical-Forecast“-Endpoint — aber dessen Archiv beginnt erst ~**Juli 2022**. Der Recheck zeigt: das 2017-Wetter ist **bit-identisch** zum Open-Meteo-Archiv (ERA5): mean_abs_diff = 0,0, max_abs_diff = 0,0, n = 168 je Variable. → Es war **Ist-/Reanalyse-Wetter (perfect foresight) = Leakage. Der +17,9 % ist ein optimistischer oberer Rand, kein leakage-sicherer Forecast-Beleg.**
3. **T11 (50 synth. Städte) [H, von Claude verifiziert]:** echtes lokales Forecast-Wetter hebt den Skill **nicht** (Median -0,5 pp; positiv 11/50; signifikant 1/50). Kein Pipeline-Fehler — sondern Beleg, dass die synthetischen Profile keine echte Wetter-Kopplung enthalten (drittes Provenienz-Signal).
4. **T12 (HEAPO, echte CH-Wärmepumpen, leakage-sicher ≥ 2022-07) [H, von Claude verifiziert]:** Median-Lift **-0,15 pp** über 26 Aggregationsrecords; signifikant besser nur 2/26. **Aber:** die Wärmepumpen- **Einzellast** trendet leicht **positiv** (+0,3... +1,6 pp, plausibel: Heizstrom $\propto$ Temperatur). Offene Verfeinerung (T13): per-MeteoSwiss-Station-Wetter statt einem Zürich-Punkt; zweiter echter Datensatz.
5. **T13 (HEAPO per-MeteoSwiss-Station-Wetter, leakage-sicher) [H, verifiziert]:** 5/8 Stationen exakt zu MeteoSwiss gematcht (bit-identische Temperatur); Wärmepumpen-Lift steigt auf **+0,6 pp** (Median), bleibt aber **nicht signifikant** (p=0,105; 5/23). Total-Last ~0. Per-Station schlägt den Zürich-Proxy um +0,2 pp. (Offenbach-Zweitdatensatz: data.zip 103 GB, Download blockiert.)

Schluss: Leakage-sicher ist der Wetter-Lift **klein ($\approx 0-1$ pp)** und allenfalls auf temperaturgekoppelter Last relevant — **kein Produkt-Moat**. Der Wert von NetzPilot liegt in der Prognose-Wedge, der Kalibrierung und der §14a-Koordination.

7. Ehrliche Grenzen

- **Stadt-Daten modelliert**, nicht gemessen (§3) → Stadt-Ergebnisse validieren die Pipeline, nicht reale Performance.
- **Keine echten Pilotdaten** (15-min-Lastgang, Kundensegmente) und **keine realen reBAP-/Bilanzkreis- Kosten** — keine belastbare €-Nutzenrechnung. Bewusst keine EUR-Aussagen.
- **Wetter-Lift** leakage-sicher klein (§6); echter Beleg braucht reale, temperaturgekoppelte 2022+-Daten.
- **Physikalischer PV/Wind-Pfad** ist MVP (kein echtes Anlagenregister, nur Wetterproxy + Bias-Korrektur).

- **Kein echtes SMGW**; produktiv nur über zertifizierten White-Label-aEMT.
 - **Open-Meteo-Lizenz** (kommerziell) vor Produktangebot klären.
-

8. Methodik (leakage-sicher by design)

- **Rolling-origin-Backtest**, Modell sieht nie Zukunft; saisonal-naiv ($\text{load}(d-7)$) als Korrekturziel.
 - **Baselines Pflicht**: saisonal-naiv **und** Persistenz, immer mitberichtet.
 - **DST-robust**: Lokaltag-Aufbereitung (`to_daily_local`) statt UTC-Reshape (sonst Stundenversatz über die Sommerzeit).
 - **Unsicherheit**: Conformalized Quantile Regression (CQR), Coverage gemessen, nicht angenommen.
 - **Signifikanz**: paired Block-Bootstrap, Block = ganzer Tag.
 - **Wetter = Forecast**: Open-Meteo **Historical-Forecast** (Archiv ab ~2022-07); ältere Perioden sind reanalysebasiert und werden klar als „perfect-foresight upper bound“ gelabelt, nie vermischt.
-

9. Reproduktion

scripts/run_backtest.py (v1) · run_t8_cqr.py (CQR national) · eval_v1_significance.py, eval_t9_significance.py (Signifikanz) · run_t10_small_utility.py (T10) · run_t11_city_weather.py (T11) · run_t12_weather_lift.py (T12 + T10-Leakage-Recheck) · eval_cities_all_load.py, eval_cities_all_residual.py, eval_cities_all_cqr.py, eval_cities_significance.py (50-Städte) · demo_control_loop.py (§14a). Detailbefunde: Notizen/_cities_finding.md, Notizen/_t10_weather_leakage_check.md, Notizen/_t12_verification.md.

10. Nächste Schritte

1. **Reale Pilotdaten** priorisieren (15-min-Last, Erzeugung, Kundensegmente, reale reBAP-Kosten) — der eigentliche Engpass; die Technik ist belegt.
 2. **T13**: Wetter-Lift leakage-sicher festnageln (per-Station-Wetter auf HEAPO-Wärmepumpenlast; zweiter echter 2022+-Datensatz).
 3. **Erzeugungsmodell** schärfen (regionale Kapazitäten, mehrere Wetterpunkte).
 4. **§14a** produktiv über zertifizierten White-Label-aEMT anbinden.
-

11. Quellen / Datensätze

SMARD (ÜNB-Netzlast, PV/Wind) · Open-Meteo Historical-Forecast (Archiv ab ~2022-07) · OPSD Household Data / CoSSMic Konstanz (data.open-power-system-data.org/household_data/) · HEAPO (Zenodo 10.5281/zenodo.15056919, arXiv 2503.16993) · §14a EnWG / BSI TR-03109-5.